Job Scheduling. Diseño y Análisis de Algoritmos

- Álbaro Suárez Valdés C-412
- Álvaro Luis González Brito C-412
- Javier Lima García C-412

Definición del problema central (P0) (Job Scheduling)

Dados n trabajos $J = \{j_1, j_2, \dots, j_n\}$, un orden parcial \prec sobre J (porque para realizar algunos trabajos, es necesario haber realizado otros previamente, esto ha de crear un DAG).

Cada trabajo i consiste en s operaciones, $\{O_{i,1}, O_{i,2}, \dots, O_{i,s}\}$ que pueden ser procesadas por alguno de cualesquiera m procesadores en ese orden.

Es posible detener la ejecución de una operación, con un costo de tiempo $C_{i,j}$ para la operación j del trabajo i. Esto significa que ese procesador no va a estar disponible esas unidades de tiempo.

Cada operación posee un porcentaje de progreso por unidad de tiempo por procesador dado por $T_{i,j,k} \in \{1,2,3,\ldots,100\}$ (porcentaje de progreso por unidad de tiempo de la operación j del trabajo i en el procesador k). O sea si esa operacion j es ejecutada en el procesador k una unidad de tiempo su progeso aumentara en ese valor. Cuando su progreso sea al menos 100, es dada por completada. Y se puede pasar a la siguiente operacion.

Cada procesador puede procesar a lo sumo una operación a la vez.

El objetivo es acabar todos los trabajos en el menor tiempo posible.

Notas:

- Se asume que el tiempo es entero no negativo.
- Ver *Anexos* para ejemplos de entrada y salida.

Motivaciones

Una solución al problema dado puede tener mucha utilidad en la práctica; dado que numerosos procesos computacionales pueden ser modelados de esta manera. Por ejemplo: un proceso compuesto por varios programas (trabajos) relacionados por un orden, que a su vez están compuestos por una cantidad finita y secuencial de instrucciones (operaciones), cada uno de los cuales debe ser ejecutado en un conjunto de computadoras (procesadores) y además existe el costo de hacer un cambio de contexto (costo de interrupción); puede darse el caso, incluso, que algunas instrucciones sean ejecutadas de manera más eficiente en algunas computadoras que en otras.

Análisis de Complejidad [1]

Nota: En esta sección trabajaremos con la versión de "decisión" de (P0), es decir, la versión en la que existe además un tiempo límite t y la pregunta es: ¿es posible terminar todos los trabajos antes de t?

Para analizar la complejidad temporal de (P0), enfoquémonos en los siguientes casos particulares.

Definición (P1) (Tiempo de ejecución unitario y Una Operación)

Dada la definición de (P0), añadimos las siguientes restricciones:

- El porcentaje de progreso por unidad de tiempo es 100 para todas las operaciones por cada procesador $(T_{i,j,k}=100, \forall i,j,k)$. En otras palabras las operaciones tienen una duración de una unidad de tiempo, independientemente del procesador en la que sea ejecutada. Como no tiene sentido interrumpir una operacion, se puede asumir que los costos de interrupcion son despreciables.
- Todos los trabajos presentan solo una operación, $s_1 = s_2 = \ldots = s_n$.

Definición (P2) (Tiempo de ejecución unitario con cantidad variable de procesadores)

Dada la definición de (P1), añadamos la restricción de que la cantidad de procesadores es variable con el tiempo.

 $c_0, c_1, \ldots, c_{t-1}$ tal que $\sum_{i=0}^{t-1} c_i = n$, donde c_i es la cantidad de procesadores en el instante i. Recordar que la pregunta es si es posible completar las tareas en t unidades de tiempo.

Tener en cuenta que es posible esta formulacion porque el tiempo de ejecución de cada tarea es unitario.

En lo que sigue asumimos que los problemas están codificados de tal forma que la longitud del string representativo de un problema de n trabajos es polinomial en n o al menos O(n).

Asumimos, además, que la codificación (encoding) es lo suficientemente natural para que los trabajos, la relación \prec , etc., puedan ser determinados de manera sencilla y por supuesto en tiempo polinomial.

Lema 1: (P2) se transforma polinomialmente en (P1)

Demostración:

Dada una instancia de (P2), introduzcamos nuevos trabajos I_{ij} para $0 \le i < t$ y $0 \le j \le n - c_i$. Mantengamos a los antiguos trabajos relacionados por \prec y añadamos $I_{ij} \prec I_{i+1,k}$ para $0 \le i < t-1$ con j y k arbitrarios. Si seleccionamos n+1 (porque de 0 a $n-c_i$ hay $n-c_i+1$ trabajos) procesadores y un tiempo límite t, tenemos una instancia de (P1).

La idea es forzar a que estos trabajos que se anadieron se tengan que ejecutar en los $n+1-c_i$ procesadores para avanzar a la siguiente ronda, quedando c_i procesadores libres, ese instante de tiempo, que es la misma situación que ocurre en P_2 .

Asumir que el trabajo I_{jk} se ejecuta en el momento l < k, entonces para poder haberlo hecho se tuvieron que haber realizado todos los trabajos de los que el depende, esto requiere

$$\sum_{i=0}^{k-1} (n+1-c_i)$$

Trabajos realizados previamente, y por tanto unidades de tiempo, pero el trabajo de procesadores disponible es a lo mas:

$$\sum_{i=0}^{l-1} (n+1)$$

Por lo que se debe cumplir que:

$$\sum_{i=0}^{l-1} (n+1) \ge \sum_{i=0}^{k-1} (n+1-c_i)$$

Esto es absurdo porque:

$$\sum_{i=0}^{l-1} (n+1) - \sum_{i=0}^{k-1} (n+1-c_i) = (l-k)(n+1) + \sum_{i=0}^{k-1} c_i$$

$$\leq -(n+1) + \sum_{i=0}^{k-1} c_i$$
< 0

El último paso es justificado porque: $\sum_{i=0}^{k-1} c_i \le n$. Esto es porque todas las tareas suman n, y esto es un subconjunto de ellas.

Esto demuestra que el tiempo del nuevo trabajo es al menos I_{ik} tienen que ser al menos k, análogamente se puede demostrar que es a lo más k, por tanto la conclusion es que todos los tiempos son exactamente k.

Con esto se concluye que una solucion de esta problema de \therefore (P1) es una solucion valida de P2, que es lo que se quiere demostrar.

La complejidad temporal de construir una instancia de (P1) es a lo sumo cuadrática respecto a la longitud de la representación de (P2). Luego, (P2) puede ser transformado polinomialmente en (P1). Debido a la arbitrariedad a la hora de construir el orden parcial, esto requiere que sea cuadrática.

Lema 2: 3-SAT se reduce polinomialmente a (P2)

Demostración:

Dada una instancia de 3-SAT con m variables $(x_i, 1 \le i \le m)$ y n cláusulas $(D_i, 1 \le i \le n)$, construyamos la siguiente instancia de (P2).

Como trabajos:

- x_{ij} y \bar{x}_{ij} para $1 \leq i \leq m$ y $0 \leq j \leq m$.
- y_i y \bar{y}_i para $1 \leq i \leq m$.
- D_{ij} para $1 \le i \le n$ y $1 \le j \le 7$.

La relación ≺ está dada por:

- $x_{ij} \prec x_{i,j+1}$ y $\bar{x}_{ij} \prec \bar{x}_{i,j+1}$, para $1 \leq i \leq m$ y $0 \leq j \leq m$.
- $x_{i,i-1} \prec y_i$ y $\bar{x}_{i,i-1} \prec \bar{y}_i$, para $1 \leq i \leq m$.
- Consideremos D_{ij} , donde $a_1a_2a_3$ constituye la representación binaria de j (Notemos que el caso en el que $a_1=a_2=a_3=0$ no puede ocurrir). Además D_i está formado por los literales z_{k_1},z_{k_2},z_{k_3} , donde cada z representa de manera independiente a x o \bar{x} , en un orden fijo. Entonces tenemos, para $1 \leq p \leq 3$, que $z_{k_p,m} \prec D_{ij}$ si $a_p=1$, o $\bar{z}_{k_p,m} \prec D_{ij}$ si $a_p=0$, donde z representa a \bar{x} o x, si z representa a x o \bar{x} , respectivamente.

El tiempo límite es m+3, y las constantes $c_i, 0 \le i \le m+2$ son:

- $c_0 = m$.
- $c_1 = 2m + 1.$
- $c_i = 2m + 2$, para $2 \le i \le m$.
- $c_{m+1} = n + m + 1.$
- $c_{m+2} = 6n.$

Debemos demostrar que esta instancia de (P2) tiene solución si y solo si la instancia de 3-SAT tiene. La idea intuitiva detrás de la demostración está en que x_i (o \bar{x}_i) es *true* si y solo si x_{i0} (o \bar{x}_{i0} , respectivamente) es ejecutado en el instante 0. Notaremos que la presencia de los trabajos y's y \bar{y} 's fuerzan a que exactamente uno de x_{i0} y \bar{x}_{i0} sea ejecutado en el instante 0 y el otro durante el instante

1. Luego, el requerimiento de que n+m+1 trabajos sean ejecutados durante el instante m+1 es equivalente al requerimiento de que por cada i, hay un j tal que D_{ij} puede ser ejecutado en ese instante (no puede haber más de uno). Pero esta condición es equiparable a decir que la cláusula D_i tiene valor true cuando aquellos x_i 's y \bar{x}_i 's que fueron ejecutados en el instante 0 recibieron valor true.

Primero, demostremos que en cualquier solución de la instancia de (P2), no podemos ejecutar ambos x_{i0} y \bar{x}_{i0} en el instante 0 para cualquier i. Supongamos que sí. Entonces, dado que $c_0 = m$, existe un j tal que ninguno de x_{j0} y \bar{x}_{j0} fue ejecutado en el instante 0. De ahí que ninguno de y_j y \bar{y}_j podrá ser ejecutado en o antes del instante j, debido a que y_j debe ser precedido por $x_{j0}, x_{j1}, \ldots, x_{j,j-1}$, cada uno ejecutado de manera estricta a continuación del anterior. Luego el total de trabajos que pueden ser ejecutados en o antes del instante j puede verse como:

- a lo sumo m(2j+1) de las x's y \bar{x} 's, es decir, $z_{i0}, z_{i1}, \ldots, z_{ij}$ fueron ejecutados en el instante 0 y $z_{i0}, z_{i1}, \ldots, z_{i,j-1}$ si no (de nuevo z representa x y \bar{x}).
- a lo sumo 2(j-1) de los y's, específicamente $y_1, \bar{y}_1, y_2, \bar{y}_2, \dots, y_{j-1}, \bar{y}_{j-1}$.

De ahí, tenemos, 2mj + 2j + m - 2. Sin embargo, para $1 \le j \le m$,

$$\sum_{i=0}^{j} c_i = 3m + 1 + (j-1)(2m+2) = 2mj + 2j + m - 1$$

(contradicción).

Podemos, entonces, concluir, que en cualquier solución a esta instancia de (P2), exactamente uno de x_{i0} y \bar{x}_{i0} es ejecutado en el instante 0. Además, podemos determinar los trabajos exactos que son ejecutados en cada instante de tiempo entre 1 y m, dado cuál de los dos, x_{i0} o \bar{x}_{i0} fue ejecutado en el instante 0. Dado que en el instante t tenemos que ejecutar t0 y t1 si no. Incluso, tenemos que ejecutar t2 (respectivamente, t3 en el instante t3 si t4 (respectivamente, t5 si t5 fue ejecutado en el instante t5 si t6 (respectivamente, t7 si t8 fue ejecutado en el instante t8 si t9 fue ejecutado en el instante t8 si t9 fue ejecutado en el instante t8 si t9 fue ejecutado en el instante 1.

En el instante m+1 podemos ejecutar los m restantes x's y \bar{x} 's y el restante y o \bar{y} . Dado que $c_{m+1}=m+n+1$, debemos ser capaces de ejecutar n de los D's si tenemos una solución. Observemos que por cada par D_{ij} y $D_{ij'}$, $j \neq j'$, hay al menos un k tal que $x_k m$ precede a D_{ij} y $\bar{x}_k m$ precede a $\bar{D}_{ij'}$, o viceversa. Como demostramos que exactamente uno de $x_k m$ y $\bar{x}_k m$ puede ser ejecutado en el instante m, se deduce que para cada i, a lo sumo uno de $D_{i1}, D_{i2}, \ldots, D_{i7}$ puede ser ejecutado en el instante m+1.

Si asignamos el valor true a x_k , (respectivamente, \bar{x}_k) si y solo si x_k0 (respectivamente, \bar{x}_k0) fue ejecutado en el instante 0, entonces existirá uno de los $D_{i1}, D_{i2}, \ldots, D_{i7}$ ejecutable en el instante

m+1 si y solo si la cláusula toma valor *true* bajo esta asignación de las variables.

Concluimos entonces que una solución a la instancia de (P2) existe si y solo si 3-SAT es satisfacible.

Teorema 1: (P1) es NP-Completo

Por **Lema 1**, **Lema 2** y que 3SAT ∈ NP-Completo.

Corolario 1: (P0) es NP-Completo

Al ser (P1) un caso particular de (P0).

Análisis de casos particulares

Problema (P3) (Simple preemptive scheduling)

Definición:

Dada la definición de (P0), añadamos las siguientes restricciones:

- $\forall i, j \exists p$ tal que $T_{i,j,k} = p, \forall k$. Es decir dada una operación su porcentaje de progreso por unidad de tiempo es el mismo para todos los procesadores.
- Todos los trabajos presentan solo una operación, $s_1 = s_2 = \ldots = s_n$.
- El costo de interrupción es despreciable.

Teorema 2: (P3) es NP-Completo

Notemos que (P1) es un caso particular de (P3) donde p = 100.

Problema (P4) (Tiempo de ejecución unitario con solo dos procesadores) [2]

Definición

Dada la definición de (P1), añadamos la restricción de que la cantidad de procesadores es 2, m=2.

Para $T,T'\in J$, diremos que T es un **predecesor** de T' y que T' es un **sucesor** de T, si $T\prec T'$. Además, si no existe tarea $T''\in J$ tal que $T\prec T''\prec T'$, entonces T es un **predecesor inmediato** de T' y T' un **sucesor inmediato** de T. El conjunto de sucesores inmediatos de T lo denotaremos como S(T).

A cualquier instancia de (P0) podemos asociarle un grafo dirigido G cuyos vértices son el conjunto de trabajos. Una arista desde el vértice Ti hasta Tj existirá si y solo si Ti es un predecesor inmediato de Tj.

Consideremos schedules para un grafo G según los cuales las tareas de G son ejecutadas por P_1 y P_2 de la siguiente manera. Sea $L=(T_1,T_2,\ldots,T_n)$ una permutación de las tareas de G. L será llamado una lista para G. Inicialmente, en el tiempo t=0, el procesador P_1 comienza a ejecutar la primera tarea en L que no tiene predecesor. Decimos que una tarea T está **lista** en el tiempo t si en este momento todos sus predecesores (si existen) ya han sido ejecutados. En general, en cualquier momento, si un procesador P_i está inactivo, escanea instantáneamente la lista L y comienza a ejecutar la tarea lista T_i con el mínimo i que aún no ha comenzado a ejecutarse. Una vez que un procesador comienza a ejecutar una tarea T, continúa ejecutando a T durante exactamente **una unidad de tiempo**, tras lo cual la ejecución de T se completa. Es decir, se asume que todas las tareas en G tienen el mismo tiempo de ejecución, y este se considera de longitud unitaria. Adoptamos la convención de que si tanto P_1 como P_2 intentan ejecutar simultáneamente la misma tarea, entonces esa tarea es ejecutada por P_1 .

El algoritmo que presentamos a continuación tiene una complejidad temporal de $O(n^2)$, lo cual, en cierto sentido, es lo mejor posible, ya que en general son necesarios $O(n^2)$ arcos para especificar un orden parcial.

Algoritmo

Presentamos a continuación el algoritmo, llamado Algoritmo A, para construir la lista óptima L^* . Primero, necesitamos la siguiente definición.

Ordenamos linealmente las secuencias decrecientes de enteros positivos de la siguiente manera. Si $N = (n_1, n_2, \dots, n_t)$ y $N' = (n'_1, n'_2, \dots, n'_{t'})$ son secuencias decrecientes de enteros positivos (donde posiblemente t = 0), diremos que N < N' si:

- lacksquare Para algún $i \geq 1$, se cumple que $n_j = n_j'$ para todo j que satisface $1 \leq j \leq i-1$ y $n_i < n_i'$, o
- $\qquad t < t' \text{ y } n_j = n_j' \text{ para } 1 \leq j \leq t.$

Sea r el número de tareas en G. El Algoritmo A asigna a cada tarea T un entero $\alpha(T) \in \{1, 2, \dots, r\}$. La función α se define recursivamente de la siguiente manera:

■ Se elige una tarea arbitraria T_0 con $S(T_0) = \emptyset$ y se define $\alpha(T_0)$ como 1.

- Supongamos que para algún $k \le r$, los enteros $1,2,\ldots,k-1$ han sido asignados. Para cada tarea T en la que α ha sido definida en todos los elementos de S(T), sea N(T) la secuencia decreciente de enteros formada al ordenar el conjunto $\{\alpha(T'): T' \in S(T)\}$. Al menos una de estas tareas T^* debe satisfacer $N(T^*) \le N(T)$ para todas las tareas T de este tipo. Se elige una de estas T^* y se define $\alpha(T^*)$ como k.
- Repetimos la asignación en (b) hasta que todas las tareas de G hayan sido asignadas a algún entero.

Finalmente, la lista L^* se define mediante el Algoritmo A como $(U_r, U_{r-1}, \ldots, U_1)$, donde $\alpha(U_k) = k$ para $1 \le k \le r$.

En las siguientes imágenes se muestra un ejemplo de un grafo y una lista L^* producida por el Algoritmo A. Nótese que existen muchas listas que satisfacen el Algoritmo A, ya que $S(T_8) = S(T_9)$, $S(T_{10}) = S(T_{11}) = S(T_{12})$, $S(T_3) = S(T_4)$, y $S(T_1) = S(T_2) = \emptyset$. El scheduling generado por L^* también se muestra en la figura.




Figura 1: Scheduling




Figura 2: Gantt Chart

Nota: Las tareas han sido indexadas de forma tal que coinciden con el valor asignado por el algoritmo A.

Demostración de optimalidad

Debido a los tiempos de ejecución unitarios, tanto P_1 como P_2 están disponibles para ejecutar tareas en los mismos tiempos. Supongamos que P_1 y P_2 están disponibles para ejecutar nuevas tareas en el tiempo t, y que T es la tarea no ejecutada cuya etiqueta es la más alta entre las correspondientes a las tareas aún no ejecutadas en el tiempo t. Para todo T' tal que $T' \prec T$, el etiquetado producido por el Algoritmo A es tal que $\alpha(T') > \alpha(T)$. Por lo tanto, en el tiempo t todos los predecesores de T deben haber sido ejecutados y T está listo para ser ejecutada. Dado que, por la construcción de L^* , P_1 y P_2 siempre intentan ejecutar la tarea pendiente con la etiqueta más alta, y dado que P_1 asigna tareas antes que P_2 por convención, vemos que T debe ser la tarea ejecutada por P_1 en el intervalo unitario que comienza en el tiempo t. Esto establece la siguiente propiedad, que presentamos en forma de lema para facilitar su referencia en la prueba de que L^* es óptima.

Lema 3

Definimos $\tau(T)$ como el entero no negativo que representa el tiempo en el que la tarea $T \in G$ comienza su ejecución en un scheduling correspondiente a la lista L^* para G. Si T es ejecutada por P_1 y $\tau(T) \leq \tau(T')$, con $T \neq T'$, entonces $\alpha(T) > \alpha(T')$.

De lo anterior también notamos que P_1 nunca está inactivo antes del tiempo $\omega(L^*)$. El resultado principal ahora sigue.

Teorema 3

Para un grafo G dado, $\omega(L^*) \leq \omega(L)$ para todas las listas L.

Demostración

Comenzamos con algunas definiciones. Supongamos que las tareas de G se ejecutan usando L^* . Si P_2 está inactivo desde el tiempo t hasta el tiempo t+1, decimos que P_2 está ejecutando una tarea vacía \emptyset y definimos $\alpha(\emptyset)=0$. Definimos recursivamente las tareas V_i y W_i de la siguiente manera:

- V_0 se define como la tarea ejecutada por P_1 que satisface $\tau(V_0) = \omega(L^*) 1$ (es decir, V_0 es la última tarea en ser ejecutada por P_1). De manera similar, W_0 se define como la tarea (posiblemente vacía) ejecutada por P_2 con $\tau(W_0) = \omega(L^*) 1$.
- En general, para $k \geq 1$, W_k se define como la tarea (posiblemente vacía) T para la cual $\alpha(T) < \alpha(V_{k-1})$, $\tau(T) < \tau(V_{k-1})$ y $\tau(T)$ es máximo. Se sigue del Lema 1 que W_k debe ser ejecutada por P_2 . V_k se define como la tarea ejecutada por P_1 que satisface $\tau(V_k) = \tau(W_k)$.

Si W_1 no existe, entonces ningún procesador está inactivo antes del tiempo $\omega(L^*)-1$ y L^* es claramente óptima. Por lo tanto, podemos asumir que W_1 (y por lo tanto V_1) existe. Supongamos

que solo podemos definir W_i para $0 \le i \le m$. Definimos \mathcal{X}_i como el conjunto de tareas T que satisfacen $\tau(V_{i+1}) < \tau(T) \le \tau(V_i)$ pero con $T \ne W_i$, $0 \le i \le m$. Dado que V_{m+1} no existe, entonces \mathcal{X}_m es el conjunto de tareas T con $\tau(T) \le \tau(V_m)$ y $T \ne W_m$.

Nótese que la cardinalidad de cada \mathcal{X}_k es impar y podemos establecer $|\mathcal{X}_k| = 2n_k - 1$ para un entero positivo n_k , $0 \le k \le m$. Un ejemplo que ilustra las definiciones anteriores es proporcionado por el diagrama de Gantt de la siguiente imagen.




Figura 3: Chi definition

El núcleo de la demostración del teorema está contenido en el hecho de que, para $0 \le k \le m$, si $T \in \mathcal{X}_k$ y $T' \in \mathcal{X}_{k+1}$, entonces $T' \prec T$. Para demostrarlo es necesario aplicar una doble inducción sobre $\tau(T)$ y $\tau(T')$ que omitiremos en este trabajo por motivos de simplicidad.

Asumiendo que, para $0 \le k \le m$, si $T \in \mathcal{X}_k$ y $T' \in \mathcal{X}_{k+1}$, entonces $T' \prec T$, entonces lo que resta es un paso corto para una prueba del teorema. Para una lista arbitraria L, todas las tareas en \mathcal{X}_{k+1} deben ejecutarse antes de que cualquier tarea en \mathcal{X}_k pueda comenzar. Dado que \mathcal{X}_{k+1} consiste en $2n_{k+1}-1$ tareas, esto requerirá al menos n_{k+1} unidades de tiempo. Así, ejecutar G requerirá al menos $\sum_{k=0}^m n_k$ unidades de tiempo, sin importar qué lista L se use. Dado que $\omega(L^*) = \sum_{k=0}^m n_k$ hemos demostrado $\omega(L) \ge \omega(L^*)$ y la prueba está completa.

Problema (P5) (Tiempo de ejecución unitario con múltiples procesadores) Definición

Dado un conjunto de m procesadores idénticos, se debe planificar la ejecución de n trabajos. Cada trabajo i tiene las siguientes características:

- **Tiempo de Ejecución:** t_i segundos (unidades de tiempo). Debido a que el progreso es uniforme en todos los trabajos y procesadores, el costo se expresa directamente en unidades de tiempo.
- Intervalo de Tiempo Permitido: Definido por un inicio s_i y un fin e_i , donde $s_i \le e_i$. El trabajo i debe completarse dentro de este intervalo $[s_i, e_i]$.
- **Independencia:** Ningún trabajo depende de la finalización de otro; es decir, no existen precedencias entre los trabajos.

 Interrupción Despreciable: El tiempo de interrupción y cambio de contexto entre los trabajos es considerado insignificante.

El objetivo es determinar si es posible ejecutar todos los n trabajos, cumpliendo con las restricciones de tiempo dadas, y en caso afirmativo, determinar un orden de ejecución factible.

Reformulación Basada en Flujos:

Para resolver este problema, se propone una solución basada en el modelado del problema como un grafo de flujo.

Construcción del Grafo:

El grafo G = (V, E) se construye de la siguiente manera:

Conjunto de Vértices (V):

- S: Nodo fuente (inicio).
- *T*: Nodo sumidero (fin).
- $R = \{r_1, r_2, \dots, r_k\}$: Representantes de los intervalos de tiempo. Donde $\{a_1, a_2, \dots, a_k\}$ es el conjunto ordenado de todos los valores únicos de s_i y e_i para todo i. Cada r_i representa el intervalo $[a_{i-1}, a_i]$.
- $V = \{v_1, v_2, \dots, v_n\}$: Representantes de los trabajos, donde v_i representa el trabajo i.

■ Conjunto de Aristas (E) y Capacidades:

- Aristas $S \rightarrow r_i$: Conectan el nodo fuente S a cada nodo representante de intervalo r_i .
 - Capacidad: $m \times (a_i a_{i-1})$. Esto representa la capacidad total de los m procesadores para trabajar en el intervalo de tiempo $[a_{i-1}, a_i]$.
- Aristas $r_i \to v_j$: Conectan cada nodo representante de intervalo r_i a un nodo representante de trabajo v_j si el intervalo $[a_{i-1}, a_i]$ está contenido dentro del intervalo de tiempo permitido para el trabajo j, es decir, si $s_j \le a_{i-1}$ y $a_i \le e_j$.
 - o Capacidad: $(a_i a_{i-1})$. Esto representa la cantidad de tiempo que el trabajo j puede ser procesado en el intervalo $[a_{i-1}, a_i]$.
- Aristas $v_i \rightarrow T$: Conectan cada nodo representante de trabajo v_i al nodo sumidero T.
 - \circ Capacidad: t_i . Esto representa el tiempo total necesario para completar el trabajo i.

Verificación de Factibilidad:

La ejecución de todos los trabajos es factible si y solo si el flujo máximo en el grafo G es igual a la suma de los tiempos de ejecución de todos los trabajos:

$$\mathsf{flujo_m\acute{a}ximo}(G) = \sum_{i=1}^n t_i$$

Si esta condición se cumple, entonces existe una asignación de trabajos a intervalos de tiempo que satisface todas las restricciones.

Determinación del Orden de Ejecución:

Una vez que se ha encontrado un flujo máximo válido, se puede determinar el orden de ejecución de los trabajos analizando el flujo en las aristas $r_i \to v_j$. Si existe flujo en la arista (r_i, v_j) , significa que el trabajo j está siendo procesado durante el intervalo de tiempo $[a_{i-1}, a_i]$. La cantidad de flujo en esta arista indica la duración de tiempo que el trabajo j está siendo procesado en ese intervalo.

Algoritmo para Calcular el Flujo Máximo: Para resolver el problema de flujo máximo en este grafo, se puede utilizar un algoritmo como **Ford-Fulkerson** o **Edmonds-Karp**. Estos algoritmos garantizan encontrar el flujo máximo en un grafo.

Complejidad:

- Construcción del Grafo: $O(n^2)$ en el peor caso, debido a la necesidad de comparar los intervalos de tiempo de cada trabajo con todos los demás. Sin embargo, se puede optimizar a $O(n \log n)$ si se ordenan los intervalos primero.
- Algoritmo de Flujo Máximo (Ford-Fulkerson): $O(E \times f)$, donde E es el número de aristas y f es el flujo máximo. En este caso, $f = \sum t_i$.
- Algoritmo de Flujo Máximo (Edmonds-Karp): $O(V \times E^2)$, donde V es el número de vértices y E es el número de aristas.

La complejidad total dependerá del algoritmo de flujo máximo utilizado. En general, se prefiere **Edmonds-Karp** para garantizar una complejidad polinómica.

Solución propuesta para (P0)

Dado que (P0) es NP-Completo, podemos afirmar que es un problema **intratable**, por lo que para resolverlo de manera eficiente solo podemos aspirar a utilizar aproximaciones y heurísticas. En la literatura podemos encontrar numerosas estrategias para resolver problemas muy relacionados (Jop Shop Scheduling -JSP- [3] es uno de ellos) como: *Priority rules*, *The shifting bottleneck heuristic*, *Opportunistic Scheduling*, *Métodos de búsqueda local* y *Métodos basados en algoritmos genéticos* (GA).

Dada la complejidad de nuestro problema, comparado con JSP (el cual podría considerarse como un caso particular, realizando pequeños ajustes) y la flexibilidad que brindan los GA, decidimos optar por un enfoque basado en estos para construir un algoritmo aproximado para (P0).

Algoritmo

```
Utilizando el marco de los GA [4]:

function GENETIC-ALGORITHM(population, fitness)

repeat

weights WEIGHTED-BY(population, fitness)

population2 empty list

for i = 1 to SIZE(population) do

parent1, parent2 WEIGHTED-RANDOM-CHOICES(population, weights, 2)

child REPRODUCE(parent1, parent2)

if (small random probability) then child MUTATE(child)

add child to population2

population population2

until some individual is fit enough, or enough time has elapsed

return the best individual in population, according to fitness
```

Necesitamos definir para nuestro problema la **codificación** de los individuos de la población, una función **fitness**, la función **REPRODUCE** (Crossover or Recombinación) y la función **MUTATE**.

Codificación

Un individuo (scheduling) está codificado como una **permutación** de todas las operaciones existentes.

Mutación

Diseñamos una mutación como el intercambio de posiciones de dos operaciones en una permutación.

Recombinación

Para recombinar dos codificaciones (permutaciones) seleccionamos de manera aleatoria a una de estas, de la cual tomamos un prefijo de longitud también aleatoria como prefijo de la recombinación resultante, a esta última la completamos con los elementos de la codificación que no fue utilizada para extraer el prefijo (manteniendo el orden original). Notemos que esta forma de recombinación garantiza que la codificación resultante es válida.

Ejemplo:

■ *c*₁: [4, 5, 6, 7, 8]

■ *c*₂: [6, 5, 4, 8, 7]

Si seleccionamos a c_1 y tomamos su prefijo [4, 5] \Longrightarrow [4, 5, 6, 8, 7]

Nota: Utilizamos enteros para representar operaciones en este ejemplo por motivos de simplicidad, en la práctica es necesario utilizar tuplas.

Fitness

El pseudocódigo de la función fitness es el siguiente:

```
function fitness(permutation)
    solution = []
    execution_list = [(operation, 0) for operation in permutation]
    repeat
        temp_execution_list = []
        for tuple in execution_list:
            if can_execute(element) and can_interrupt(solution, tuple):
                 interrupted = best_interrupt(solution, tuple)
                 temp_execution_list.append(tuple)
                 else:
                      temp_execution_list.append(tuple)
                 execution_list = temp_execution_list
                 until execution_list is empty

return 1 / latest interval(solution)
```

Dado una permutación el objetivo de *fitness* es calcular su fitness, valga la redundancia. Para alcanzarlo este se apoya de una **heurística greedy**. Primero construye una **lista de ejecución** cuyos elementos son tuplas -operación, progreso-, (inicialmente el progreso es 0 -una operación finaliza cuando su progreso es 100-). A continuación recorre la lista de ejecución y por cada tupla verifica si su operación es **ejecutable** -can_execute- (una operación es ejecutable si todas las operaciones predecesoras han finalizado -operaciones de su trabajo como de trabajos predecesores-) y si puede **interrumpir** -can_interrupt- a alguna de las últimas operaciones dispuestas por procesador en la solución actual; si ambas condiciones son alcanzadas entonces se interrumpe (y es añadida a la próxima lista de ejecución) la última operación de uno de los procesadores que conduce al menor tiempo de ejecución -best_interrupt- (*greedy approach*). Notemos que interrumpir implica interrumpir directamente o sustituir a dicha operación.

Al finalizar el while (repeat-until en este caso) tenemos una solución factible (garantizado por can_execute), de la cual podemos conocer su tiempo de ejecución total, a partir de la operación más tardía de las últimas operaciones por procesador -latest_interval-.

Notemos que durante cada iteración del while, disminuye en al menos un elemento la lista de ejecución; además la complejidad de $can_execute$ puede ser O(1) si mantenemos una estructura de tipo diccionario durante cada iteración del while (complejidad O(n)), la complejidad de $can_interrupt$ es O(m) y la de $can_interrupt$ es can de can de

$$\sum_{i=0}^{l-1} m(l-i) + n = ml^2 + nl \implies O(ml^2 + nl),$$

donde l representa la cantidad total de operaciones.

Referencias bibliográficas

- 1 Ullman, J. D. (1975). NP-complete scheduling problems. Journal of Computer and System Sciences, 10(3), 384–393. https://doi.org/10.1016/S0022-0000(75)80008-0
- 2 Coffman, E. G., Graham, R. L. (1972). Optimal scheduling for two-processor systems. Acta Informatica, 1(3), 200–213. https://doi.org/10.1007/BF00288685
- 3 Błażewicz, J., Domschke, W. Pesch, E. (1996). The job shop scheduling problem: Conventional and new solution techniques. European Journal of Operational Research, 93(1), 1–33. https://doi.org/10.1016/0377-2217(96)00030-3
- 4 Russell, S. J. Norvig, P. (2020). Artificial intelligence: A modern approach (4th ed.). Pearson.

Anexos

Entrada

- Un diccionario con trabajo como llave y como valor los trabajos de los que depende.
- Una lista en la que cada índice representa un *trabajo*, y sus elementos son listas que indican el *costo de interrupción de sus operaciones* (dispuestas en su orden de ejecución).
- Una lista en la cada índice representa un *trabajo*, y sus elementos constituyen matrices que indican el *porcentaje de progreso por segundo de una operación en un procesador*.

Ejemplo

(3 trabajos y 2 procesadores)

```
{
    3: [1, 2]
}
El trabajo 3 depende de la culminación del 1 y 2 para poder comenzar.
[
    [20, 21, 22],
    [23],
    [24, 23]
]
```

El trabajo 1 esta formado por 3 operaciones, el 2 por 1 y el 3 por 3. Cada una presenta su respectivo costo de interrupción, por ejemplo: $C_{1,2}=21, C_{3,1}=24$.

```
[
        [30, 35],
        [50, 55],
        [50, 40]
],
        [
        [30, 20]
],
        [
        [10, 12],
        [15, 20]
]
```

Porcentaje de progreso por segundo; por ejemplo: $T_{1,1,1} = 30, T_{1,1,2} = 35, T_{2,1,2} = 20, T_{3,2,1} = 15.$

Salida

Una lista en la que cada índice representa un *procesador* y sus elementos constituyen una tupla formada a su vez por dos tuplas: *intervalo de uso y operación realizada durante dicho intervalo*.

Nota: Se asume que toda salida debe ser factible.

Ejemplo

```
[((0, 5), (1, 1)), ((9, 12), (2, 1)), ((15, 20), (2, 2)), ((30, 35), (3, 1))]
```

[((6, 9), (1, 2)), ((15, 17), (1, 3)), ((23, 28), (4, 1))],

]